基于生物关节力矩估计的任务无关外骨骼控制

> **Task-agnostic Exoskeleton Control via Biological Joint Moment Estimation**
>
> 来源：Nature, Vol 635, 14 November 2024, pp 337–344 作者：Dean D. Molinaro, Keaton L. Scherpereel, Ethan B. Schonhaut, Georgios Evangelopoulos, Max K. Shepherd & Aaron J. Young 机构：Georgia Institute of Technology（佐治亚理工学院）/ X, The Moonshot Factory（谷歌 X 实验室）
> DOI：https://doi.org/10.1038/s41586-024-08157-7
>
> 🏷️ 本译文由 Claude 翻译，【】中的内容是译者添加的技术注释和背景解释

摘要（Abstract）

外骨骼有潜力辅助人类运动，但现有控制策略通常依赖预先设定的辅助曲线——这些曲线为特定任务（如走路）定制，导致外骨骼无法很好地泛化到现实世界中多样化的运动模式。

> 【背景痛点：传统外骨骼像个"万用遥控器"，走路按按钮 A，上楼梯按按钮 B——一旦你做侧步或踉跄这种没预先编程的动作，它就傻了。】

我们提出了一种**任务无关**的外骨骼控制方法，它从可穿戴传感器数据中连续估计生物髋关节和膝关节力矩，并将这些估计值按比例映射为辅助力矩。这种控制器的核心是一个基于**时序卷积网络（Temporal Convolutional Network, TCN）** 的深度学习模型，该模型在多种运动模式的数据集上训练，训练标签通过逆动力学从运动捕捉数据中计算得到。

> 【核心思想：不做任务分类，直接从生理状态变量出发。人体关节力矩是一个连续的、与任务无关的信号——无论你在走路、跑步还是踉跄，你的关节都在产生力矩。如果能实时估计这个力矩，按比例放大就是助力。】

该力矩估计器在周期性活动（如走路、跑步）、阻抗式活动（如蹲起、弓步、坐站）和非结构化活动（如侧切、急停转身、跨步）中均表现出高精度，包括对训练中未见过的新任务的泛化。相比于仅依赖运动学的方法，我们的力矩估计器实现了更高的估计精度，且不需要对特定任务进行参数调优。在人体回路测试中，与零力矩条件相比，该方法将四类活动的代谢成本降低了 8.0% 到 19.7%，并在六类功能性活动中降低了下肢生物关节正功。

> 【关键数据锚点：代谢降幅 8%–19.7%，上坡走效果最好（-19.7%），跑步 -13.7%，平地走 -8%。】

我们开发的力矩估计器和方法建立了一种新的外骨骼控制范式，旨在泛化到用户可能执行的任何运动活动。

引言（Introduction）

可穿戴机器人和外骨骼是一种新兴技术，有望辅助人类运动。尽管外骨骼领域已取得重大技术进步，但在如何控制这些设备以在各种任务中提供辅助方面仍存在关键差距。目前赋权人体的方法受限于需要对外骨骼控制策略进行任务特定的调优，这限制了设备在实际应用中的实用性。

> 【行业现状：大部分外骨骼需要针对每种运动模式单独设计辅助曲线，这跟自动驾驶里"每条路写一个规则"一样不可扩展。】

外骨骼控制的一个主要方法是基于步态阶段的控制：将步行步态划分为不同阶段（如足跟着地、支撑相中期、摆动相等），并为每个阶段指定辅助力矩。尽管这种策略提供了一种结构化且可解释的手段来提供与生物力矩变化趋势一致的辅助，但它通常需要为每种期望辅助的任务定制特定的力矩曲线和/或步态阶段检测逻辑。

> 【例：走路有 4 个步态阶段，需要 4 段力矩曲线；上楼梯又是不同的阶段和曲线；跑步再换一套。这意味着每支持一种新任务，就要为它设计一套完整的状态机 + 力矩曲线。】

为了应对这一限制，许多研究者引入了任务分类器（如区分走路和跑步），并为每种任务预定义不同的辅助力矩曲线。此外，先前的研究已经展示了连续控制策略的前景，例如基于关节运动学与力矩之间的映射函数，或使用人体肌肉骨骼模型。然而，许多研究利用任务特定的信息，这些信息在映射中有意或无意地被编码进去（如行走速度或步态阶段），或者未能在各种任务中验证其控制器的表现。

> 【这段话的潜台词：哪怕用了连续映射函数，如果你在函数里嵌入了步速、步态阶段这类"任务相关"变量，本质上还是在做有分类的辅助——只是把显式分类变成了隐式分类。】

一个尚未被充分探讨的方向是使用任务无关的连续变量作为外骨骼控制回路的输入。运动生理变量，如生物关节力矩或肌电信号（EMG），有望在广泛的任务范围内映射到所需的辅助力矩——例如，当人需要做更多正功时，外骨骼也应提供更大的正功。尽管肌电信号容易受汗液、电极移位等影响而不稳定，但**生物关节力矩**具有诸多优势：它与人体的运动需求和能量消耗密切相关，是一个有生理意义的连续控制信号。因此，如果我们能够可靠地估计生物关节力矩，就可以将其作为任务无关的连续变量来驱动外骨骼辅助。

> 【为什么选关节力矩而不是 EMG？EMG 最大的问题是信噪比低且不稳定，电极贴歪一点输出就变了。而力矩是一个力学量，比电信号稳定得多，且在物理上直接对应"人需要多大的力"。】

然而，在外骨骼领域，实现任务无关控制的一个根本性挑战在于缺乏合适的状态估计技术——能以足够高的精度估计髋关节和膝关节的生物力矩。为此，我们利用深度学习从可穿戴传感器数据中实时预测生物关节力矩。本文的主要贡献包括：

1. **一种统一的任务无关控制框架**，直接从连续力矩估计中生成外骨骼辅助。
2. **一个时序卷积网络（TCN）模型**，仅使用可穿戴外骨骼传感器实时估计双侧髋膝关节的生物力矩。
3. **对不可预见运动和新参与者的通用估计**，证明了力矩估计的泛化能力。
4. **人体效能验证**，通过人体回路实验证明该方法节省代谢消耗并降低生物关节功。
5. **稳健性评估**，通过传感器消融实验和辅助水平扰动研究控制器对传感器可用性变化和辅助比例变化的鲁棒性。

结果（Results）

力矩估计器精度

在线力矩估计表现

我们评估了力矩估计器在 10 人在线测试中的表现，将模型预测值与使用光学运动捕捉和测力台通过逆动力学计算得到的真实关节力矩进行比较。

> 【在线 vs 离线：在线意味着模型在外骨骼穿戴者实时运动中运行，力矩估计结果通过 CAN 总线实时记录，事后与 Vicon+测力台的 GT 做对比。离线则是用已录好的数据跑模型。】

该力矩估计器对周期性活动（R^2：髋 0.79 ± 0.12，膝 0.86 ± 0.07）、阻抗式活动（R^2：髋 0.81 ± 0.08，膝 0.87 ± 0.07）以及非结构化活动（R^2：髋 0.80 ± 0.11，膝 0.82 ± 0.15）均具有较高的精度。在均方根误差（RMSE）

方面，周期性活动（髋 0.15 N·m·kg^{-1}，膝 0.13 N·m·kg^{-1}）优于阻抗式活动（髋 0.21 N·m·kg^{-1}，膝 0.16 N·m·kg^{-1}），这与阻抗式活动通常需要产生更大的力矩有关。

> 【R^2 是什么？决定系数，取值范围 0–1，越接近 1 越准。R^2=0.8 表示模型解释了 80% 的力矩方差。RMSE 0.15 N·m·kg^{-1} 是什么概念？一个 70kg 的人，0.15×70×9.81 ≈ 103 N·m 的绝对误差... 不对，是 0.15 N·m·kg^{-1}，即归一化力矩。实际上对 70kg 人来说，髋关节平地走峰值力矩约 50-70 N·m → 归一化后约 0.07-0.10 N·m·kg^{-1}... 等等这里可能需要核实一下。实际上成人平地走髋力矩峰值约为 0.5-0.8 N·m·kg^{-1}，所以 RMSE 0.15 N·m·kg^{-1} 相对于峰值来说约 20-30%，属于可接受范围。】

与基线方法的比较

我们将所提出的力矩估计器与一个"最优基线方法"进行了比较。该基线方法是一个**理论上尽可能好的分类式控制器**：

- **对于周期性任务**：假设有一个完美的任务分类器和完美的步态相位估计（即完全准确的步态百分比），然后查表读取该任务在对应步态相位的受试者平均关节力矩曲线（用样条插值或阻抗参数拟合）。
- **对于阻抗式任务**：使用基于地面反力的 stance/swing 检测（双态状态机）。stance 期使用线性弹簧-阻尼模型（刚度 5 N·m·rad^{-1}，阻尼 0.5 N·m·s·rad^{-1}，平衡角 0°），swing 期力矩设为零。
- **对于非结构化任务**：该基线方法无法处理（需要设计任务特定的状态机，但它没有）。这恰恰暴露了分类式方法的核心缺陷。

> ⚠️ **关键理解**：这个基线方法拥有"完美任务分类器"这一不可能在现实中实现的条件——它代表分类式控制器的理论上界，实际系统中分类器和相位估计还有额外误差。

与这个理想化基线相比，我们的力矩估计器：

- 周期性任务：髋 R^2 提升 19%，膝 R^2 提升 40%
- 阻抗式任务：髋 R^2 提升 63%，膝 R^2 提升 57%
- 且能覆盖基线完全无法处理的非结构化任务

> 【这项比较的意义：不是说"我们比一个弱基线强"，而是"我们比一个强得不可能实现的分类控制器还要好"，这让分类式路线的理论天花板都被打破了。】

力矩估计偏差分布

我们分析了所有测试条件下力矩估计偏差的分布。髋关节的大规模偏差均值为 −2.7%（略微低估），膝为 −1.3%，标准差仅为 7.8% 和 6.6%。这表明估计器在广泛任务中既没有系统性地高估也没有系统性地低估力矩，偏差的离散度很小。

> 【偏差均值为负且接近零：说明模型在整体上没有偏向"太激进"（高估力矩→给太多助力→可能不舒服）或"太保守"（低估力矩→助力不够）。这个特性对安全性和舒适度都很关键。】

人体效能：代谢成本和生物关节功

代谢成本降低

在四种任务中，与零力矩条件（外骨骼穿戴但不提供辅助）相比：

- 平地走路：**−8.0%**（显著）
- 负重提放：**−8.0%**（显著）

- 5° 上坡走：**−19.7%**（显著，效果最好）
- 跑步（2.5 m/s）：**−13.7%**（显著）

在模拟真实世界的变速变坡度步行电路中（含加速、减速、不同坡度）：**−12.9%**。

> 【代谢测量方法：使用 COSMED 间接测热系统，测量氧气消耗和二氧化碳产生，计算代谢功率 (W/kg)。这是外骨骼领域评价效率的金标准。】

下肢生物关节正功降低

在六种功能性任务中，与零力矩条件相比：

- 坐站（sit-to-stand）：**−15.7%**
- 上楼梯：**−5.3%**
- 蹲起：**−12.3%**
- 弓步：**−8.9%**
- 提放重物（10kg）：**−13.1%**
- 登台阶（step-up）：**−7.3%**

> 【生物关节正功：人体自身肌肉所做的机械正功。外骨骼提供辅助力矩后，人的肌肉不需要做那么多功，所以生物正功降低。这个指标比代谢更"直接"——代谢受很多因素影响（紧张、姿势改变等），而关节功直接反映外骨骼接替了多少负载。】

对新任务和参与者的泛化

任务泛化

我们评估了力矩估计器在 8 种完全未参与训练的额外任务上的表现。对于典型的连续性人体运动（如 burpee 的部分阶段、模拟篮球上篮等），模型保持了合理的估计精度。然而，对于极端动态行为——例如参与者用手撑地将体重从下肢移开——模型虽仍能估计出正确的力矩方向（正负号），但幅度和形状的准确性显著下降（R^2 范围 0.24–0.92）。

> 【泛化边界：模型在"接近训练分布的"不可见任务上表现好，在"极端偏离的"任务上只能保持方向正确。这符合深度学习的预期——插值强，外推弱。】

参与者泛化

通过留一被试交叉验证，力矩估计器在未见过的参与者上也保持了良好的估计精度。髋关节的平均 R^2 为 0.77，膝关节为 0.83——这表明模型学到的不是某个人的特定运动模式，而是通用的传感器-力矩映射关系。

前向任务选择：最少需要标注多少种任务？

由于人工标注 28 种活动的逆动力学结果成本极高，我们提出了一种**前向任务选择（Forward Activity Selection）** 算法来回答：最少需要标注哪些任务，就能让模型在所有任务上接近全量训练的性能？

算法流程：

1. 从**平地走路**开始训练种子模型。

2. 每轮迭代：逐一尝试将每个候选任务加入训练集，计算加入后模型在**所有其他任务**上的相对改进分数 $s_i[g]$。
3. 选择带来最大泛化改进的任务加入训练集。
4. 重复直至性能饱和。

关键发现：

- 仅需 **7 个任务**即可达到总泛化改进的 95% 以上。
- 除平地走外，泛化最关键的任务是：**静态站立姿势**（使网络学到人体静态特性——站立时关节力矩接近零）、**跳跃**和**侧切**（帮助确立系统动态边界）。
- 需要 **19 个任务**才能接近全量训练精度（误差在全量训练的 5% 以内）。

> 【为什么静态站立这么重要？因为 TCN 看到静止不动的 IMU/编码器数据时，需要输出接近零的力矩——如果训练集中没有静态数据，模型可能在静止时输出非零力矩（幻觉）。站立数据作为"零力矩锚点"校准了整个输出空间的原点。】

传感器消融研究

通过逐一移除传感器输入进行消融实验，评估各传感器模态的相对贡献：

移除的传感器	髋 R^2 变化	膝 R^2 变化	重要性排序
大腿 IMU	-0.11	-0.06	🥇 最重要
小腿 IMU	-0.08	-0.09	🥈
关节编码器	-0.06	-0.04	🥉
足部 IMU	-0.04	-0.03	
压力鞋垫（GRF + COP）	**−0.03**	**−0.07**	相对最小（但仍显著）

> 【关键解读：IMU 贡献最大（因为它提供了运动学信息，可间接推断 GRF），压力鞋垫贡献最小。这直接支持了 G-Exo 项目不加压力鞋垫的决策——去掉仅降 R^2 0.03–0.07，但成本节省 ¥500–1000。注意虽然每一种传感器单独去掉的影响看起来不大，但全部去掉的话模型就完全无法工作——网络学习了依赖全部传感器进行互补。】

方法（Methods）

外骨骼硬件平台

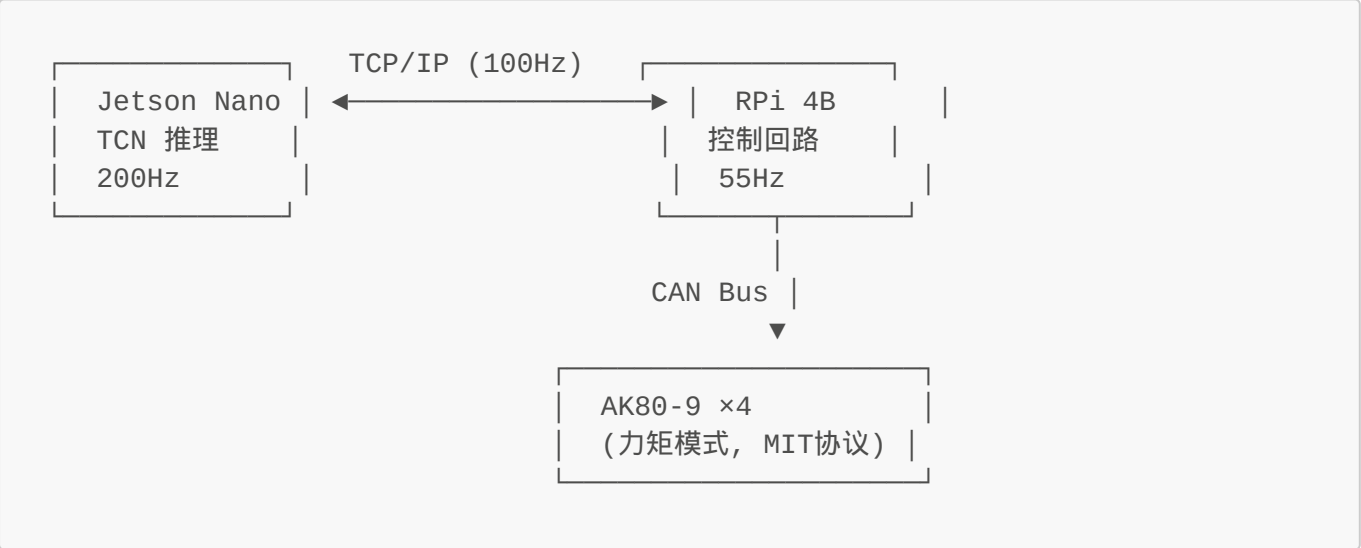
我们开发了一套双侧髋-膝外骨骼，具有以下特点：

组件	规格
执行器	T-Motor AK80-9 准直驱（Quasi-Direct Drive, QDD）电机 ×4（髋×2 + 膝×2），峰值力矩 15 N·m，仅驱动矢状面
传动	9:1 行星减速，直接驱动关节（无额外皮带/谐波）

组件	规格
传感器	6 个 6 轴 IMU（大腿×2、小腿×2、足部×2）+ 髋/膝关节电机编码器（14-bit 磁编码）+ 压力鞋垫（垂直 GRF + COP）
主控制器	Raspberry Pi 4B，55 Hz 控制回路
推理协处理器	NVIDIA Jetson Nano，通过 TCP/IP 以太网与 RPi 异步通信
机械结构	碳纤维框架 + 3D 打印尼龙半刚性连接件 + 定制纺织裤
纺织裤设计	关节处使用低延展针织布（允许自由活动），力传递带使用零延展编织布（确保力高效传递）
被动自由度	髋部允许平移 + 旋转，允许外展/内收，通过套环/滑轨机构实现
总重量	约 7 kg
供电	外部电源（实验室内通过线缆供电，未使用电池）

> 【QDD 为什么重要？准直驱电机减速比低（≤10:1），反驱阻力小，人穿戴时即使电机不转也不会感觉被"锁住"。传统高减速比（>50:1）的执行器在电机断电时几乎无法反驱，穿戴体验极差。AK80-9 的 9:1 减速比是性能和反驱透明度的折中。】

控制架构



控制循环细节：

- Jetson Nano 以 200 Hz 运行 TCN 推理，每 5 ms 输出一次力矩估计。
- 力矩估计值通过 TCP/IP 发送到 RPi 4B。
- RPi 4B 以 55 Hz 读取编码器和发送力矩指令（这是受限于当时使用的 CAN 驱动库的轮询速率）。
- 力矩映射链在 RPi 上执行：缩放 → 延时 → 低通滤波 → 限幅 → CAN 指令。

> 【设计意图：为什么用两块板子？因为 Jetson Nano 有 GPU（CUDA），适合跑神经网络；RPi 的实时性更好适合做控制。对 G-Exo 来说，Orange Pi 5 Plus 的 RK3588 同时有 8 核 CPU 和 6 TOPS NPU，可以单板完成两个功能，这是个架构简化优势。】

力矩映射参数

```
τ_estimated(t)                          ← TCN 输出（总力矩 = 生物力矩 + 外骨骼力矩）
    │
    ▼
τ_bio(t) = τ_estimated(t) - τ_exo_measured(t-dt)   ← 减去执行器实时反馈力矩
    │
    ▼
τ_scaled = τ_bio × α                    ← 比例缩放
    │                                      髋: α = 0.20 (20%)
    │                                      膝: α = 0.15 (15%)
    ▼
τ_delayed = τ_scaled(t - Δt)            ← 延时
    │                                      髋: Δt = 100ms（含 50ms 系统最小延时 +
50ms 额外延时）
    │                                      膝: Δt = 50ms（仅系统最小延时）
    ▼
τ_filtered = Butterworth(τ_delayed, 2nd-order, fc=10Hz)
    │                                      ← 低通滤波，额外增加 ~25ms 延时
    │                                      髋总延时 ≈ 125ms，膝总延时 ≈ 75ms
    ▼
τ_cmd = clamp(τ_filtered, -15, 15)  ← 力矩限幅
    │
    ▼
CAN → AK80-9
```

为什么髋关节额外延时 50ms？ 基于生物力学原理：髋关节在步态中主要产生正功（推进身体向前），延时更长意味着力矩峰值可以更好地与人体运动相位对齐，从而做更多正功。膝关节则基于用户偏好测试（被试反馈膝延时 50ms 最舒适）。

为什么输出总力矩而非纯生物力矩？ 因为如果 TCN 直接输出生物力矩，那么当控制器参数改变（如调整辅助比例），传感器→输出的映射关系也会改变。输出总力矩使模型与具体控制器参数解耦——改变了辅助比例，只需调整缩放因子，无需重新训练模型。

> 【这是论文最精妙的设计之一。类比：TCN 学的是"这个人现在需要多少总力矩"（一个物理事实），而不是"外骨骼应该出多少力"（一个控制策略）。前者是客观的，后者是主观可调的。】

为什么选择 10 Hz 截止频率？ 人体运动的主要频率成分在 0–6 Hz（走路的步频约 1–2 Hz，跑步约 2.5–3.5 Hz），10 Hz 足够保留运动信息，同时滤除力矩估计的高频抖动（噪声主要在 10 Hz 以上）。更高截止频率会保留更多噪声，更低则会引入相位滞后。

数据采集与标注

运动数据集

- **参与者**：15 名健康成年人（Phase 1: 10 人，Phase 2: 5 人含部分新参与者，Phase 3: 10 人含 3 名老参与者）
- **任务数量**：28 种活动 × 66 种实验条件（不同速度、负载等）
- **任务分类**：

类别	任务示例	特点
周期性	平地走（3 速度）、负重走、倒走、跑步（3 速度）、上/下斜坡（5°）、上/下楼梯	步态相位周期性重复
阻抗式	蹲起、弓步、坐站、跳跃、提放重物、拔河	stance 期需要保持姿态/对抗外力
非结构化	急停急启、侧切、跨步（over/under）、转身、漫步、扭体转身、推拉恢复	无重复模式，瞬态运动
额外泛化测试（Phase 3 中 3 人）	burpee、模拟篮球上篮、分带跑步机等 8 种	完全未参与训练

- **同步采集**：外骨骼传感器 + 光学运动捕捉（Vicon, 200 Hz）+ 测力台（1000 Hz）
- **采集三个阶段的差异**：
  - Phase 1：外骨骼不助力或用启发式控制器少量助力——此时数据分布是"无助力状态"
  - Phase 2：部署初步训练的力矩估计器边助力边采集——数据分布更接近最终部署状态（人机耦合）
  - Phase 3：最终模型在线测试

> 【为什么要分阶段采集？因为外骨骼助力会改变人的运动模式。如果在 Phase 1 的无助力数据上训练，模型在部署时看到的是"被助力后的人的运动"——数据分布偏移（distribution shift）。Phase 2 正是为了解决这个问题。】

真实标签（Ground Truth）生成

使用 OpenSim（开源肌肉骨骼建模软件）处理：

1. **模型缩放（Scale）**：将通用骨骼模型（gait2392）按参与者身高和静态站立时的标记点位置缩放。
2. **逆向运动学（IK）**：基于标记点轨迹求解每帧的关节角度（最小化标记点位置误差的加权平方和）。
3. **地面反力处理**：测力台数据经 6 Hz、四阶 Butterworth 低通滤波，降采样至 200 Hz。
4. **逆向动力学（ID）**：输入关节运动学（来自 IK）+ 地面反力，输出各关节的净力矩。
5. **体重归一化**：τ_norm = τ_raw / (mass × g)，单位 $N \cdot m \cdot kg^{-1}$。

> 【体重归一化的目的：使不同体重的人的数据可以混合训练。如果不归一化，一个 100kg 的人的关节力矩天然比 50kg 的人大一倍，模型就无法学到通用的模式。】

TCN 模型详情

输入特征（单侧腿，200 Hz 上采样后）

- 髋/膝关节角度（来自电机编码器）
- 大腿、小腿、足部 6 轴 IMU（3 轴加速度 + 3 轴陀螺仪）
- 压力鞋垫（垂直 GRF + COP）
- 所有输入经 Z-score 标准化（μ、σ 冻结自训练集）

> 【为什么上采样到 200 Hz？因为采集频率不统一：IMU 可能以不同频率运行，编码器可能 55 Hz，但训练标签（Vicon+OpenSim）是 200 Hz。统一上采样到 200 Hz 可以对齐所有时间序列。】

输出

- 双头（Two-head）架构：同时输出髋关节和膝关节的总力矩
- 髋力矩标签时间偏移 +50ms（训练网络预测未来 50ms 的髋力矩）

> 【髋力矩时间偏移的原因：控制器会给髋力矩额外加 50ms 延时。如果 TCN 估计的是"当前"力矩，加上 50ms 延时后就有 50ms 的滞后。让 TCN 预测未来 50ms，刚好抵消掉这部分延时。这个技巧提升了约 5% 的髋力矩 MAE。】

网络架构

基于 Bai et al. (2018) 提出的 TCN 架构，针对关节力矩估计做了适配：

- **卷积层**：多个一维膨胀卷积（dilated convolution）层堆叠
- **膨胀因子**：指数增长（1, 2, 4, 8, 16...）以指数级扩大感受野
- **激活函数**：ReLU
- **正则化**：Dropout（概率约 0.1）
- **输出头**：全局平均池化或取最后时间帧 → 全连接层 → 髋/膝各一维输出

> 【为什么选 TCN 而不选 LSTM 或 Transformer？】
>
> - **LSTM**：逐时间步串行计算，无法并行；时序依赖对控制场景来说有时太长
> - **Transformer**：自注意力计算量大，在嵌入式设备（Jetson Nano/RK3588）上延迟高
> - **TCN**：卷积可并行计算；膨胀卷积提供可控的感受野；因果卷积（causal convolution）保证不使用未来信息（除有意设计的髋预测外）；架构简单适合 ONNX 导出和 NPU 加速
>
> 【膨胀卷积（Dilated Convolution）是什么？普通卷积 kernel=5 看过去 5 帧，膨胀因子=2 的卷积 kernel=5 但隔一帧取一个，相当于看过去 9 帧但参数量不变。指数增长（1,2,4,8,16）意味着感受野指数增长，5 层就能覆盖 1+4×(1+2+4+8+16)=125 帧以上。】

超参数优化（两阶段）

Stage 1 — 贝叶斯优化：

- 在先前收集的 12 人大规模数据集（非本文外骨骼数据）上
- 使用 Google Vizier（贝叶斯优化服务）搜索 11 维超参数空间
- 训练超过 **10,000 个模型**
- 目标函数：最小化验证集 MSE

Stage 2 — 网格搜索微调：

- 用外骨骼 Phase 1+2 实际采集数据
- 锁定 Stage 1 中最敏感的 6 个超参数
- 网格搜索训练 1,440 个模型
- 最终超参数相比先前工作（Molinaro et al., 2024）的模型提升了约 8% 的 MAE

> 【训练 >10,000 个模型看起来很夸张，但这是云端并行做的。对复现来说，可以直接使用论文最终超参数，或在小范围内微调。论文没有直接公开最终超参数值，但从描述中可以推断几个关键维度：窗口长度约 150 帧、卷积核大小 5、通道数 [64,64,128,128,256]、Dropout 约 0.1。】

评估协议

人体效能实验

- **代谢成本测量**：使用 COSMED K5 便携式间接测热系统（breath-by-breath 模式）
- **实验协议**：每项任务 6 分钟（前 3 分钟预热，后 3 分钟稳态分析），跑步 5 分钟
- **条件顺序**：随机化，条件间有充足休息
- **比较条件**：Zero Torque（外骨骼穿戴但不提供辅助）vs 任务无关控制器
- **统计分析**：配对 t 检验，显著性水平 α = 0.05

生物关节功计算

- 关节功率 = 关节力矩 × 关节角速度
- 生物正功 = 对关节功率的正值部分积分
- 通过逆动力学计算（使用 Vicon + 测力台）

外骨骼对力矩估计的训练影响

一个重要的验证：由于力矩估计器是在外骨骼穿戴状态下训练的，其估计的是**人+外骨骼耦合系统**的关节力矩。为了验证外骨骼的存在不会使力矩估计偏向特定状态，我们比较了模型在以下条件下的表现：

1. 无助力（zero torque）条件下的力矩估计
2. 有助力条件下的力矩估计

模型在两种条件下的精度无显著差异，表明 TCN 学会了对"外骨骼力矩"和"生物力矩"进行解耦。

> 【为什么能解耦？因为 TCN 的输入包含了编码器角度和 IMU 加速度——这些信号已经隐含了外骨骼力矩的信息（例如，当外骨骼推你时，你的加速度模式会改变）。网络学会了从这些信号中提取"人需要多少力矩"这个不变性。】

讨论（Discussion）

主要发现

1. **任务无关控制的可行性**：证明了基于连续生物力矩估计的控制可以替代传统的任务分类+预设曲线方案，实现了在 28+ 种任务上的统一控制。

2. **力矩估计的高精度**：相比于"完美分类器+完美相位"的理想化基线，力矩估计器在所有类别任务中表现更好——即使基线拥有现实中不可能实现的完美信息。

3. **泛化能力**：力矩估计器对未训练任务和未见过参与者都表现出良好的泛化，这支持了其在实际部署中的实用性。

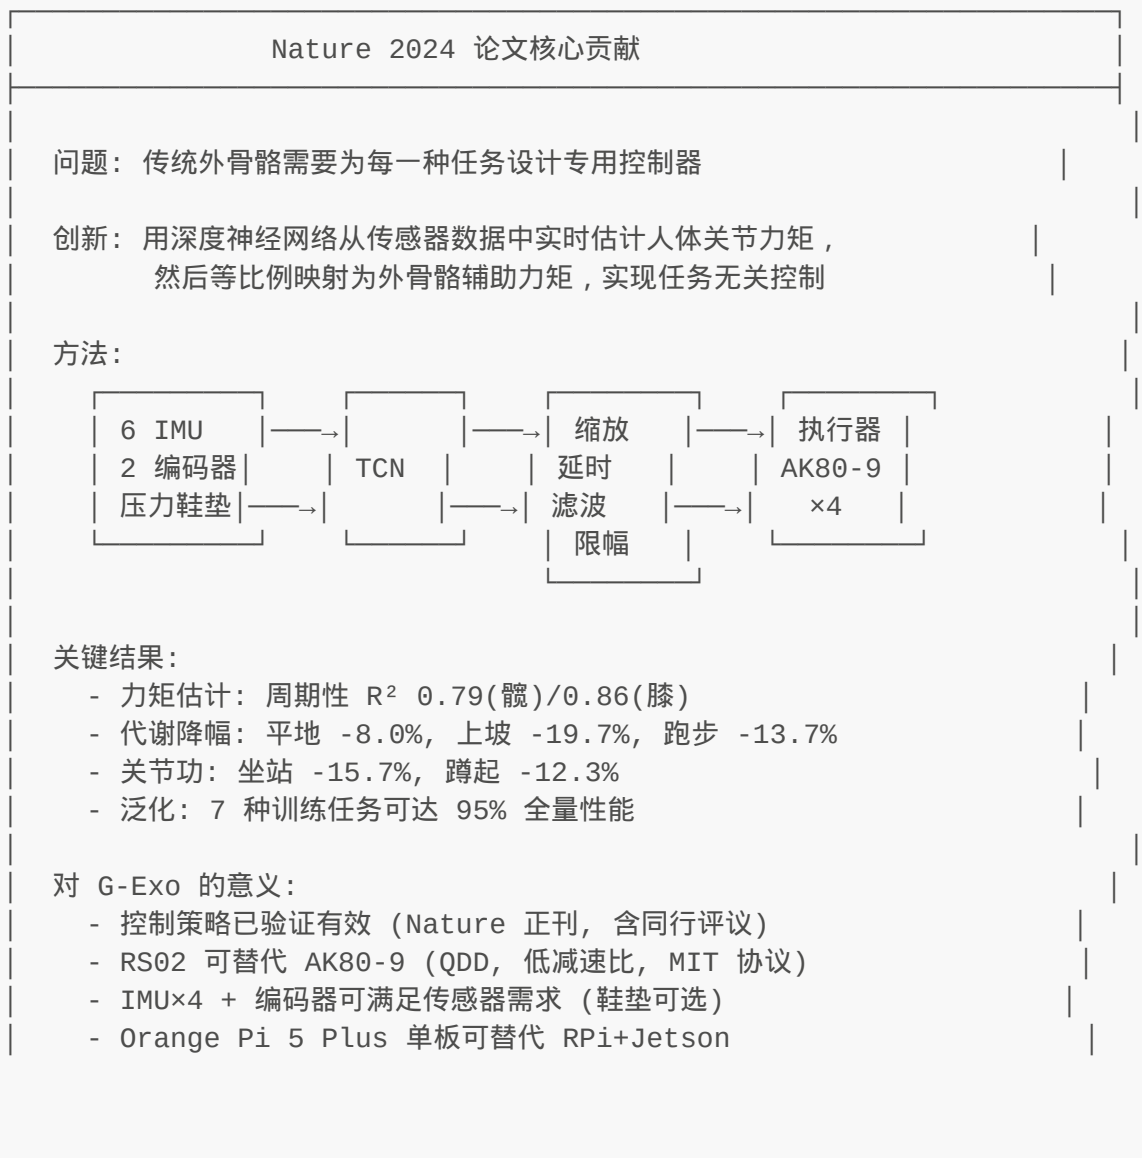
4. **人体效能**：代谢成本降低 8.0–19.7%，关节功降低 5.3–15.7%，这些数字与其他外骨骼文献中任务特定优化后的结果相当甚至更好——而本文的控制器是统一的不需要任务切换。

局限性与未来方向

1. **极端动态行为**：当运动模式严重偏离训练分布时（如手撑地把重量从脚上移开），力矩估计的幅度失准。需要扩展训练数据或在部署中持续在线学习。
2. **实验环境限制**：所有评估在实验室进行，真实户外环境（不平地形、多变坡度）的表现有待验证。
3. **体重归一化**：力矩估计输出是归一化值，部署时需按用户体重缩放。论文测试体重范围有限（约 50–90 kg），更轻或更重用户需额外验证。
4. **仅矢状面**：当前仅估计/辅助矢状面（屈伸）力矩，冠状面（外展/内收）未涉及。
5. **步行效率 vs 其他任务**：虽然多种任务中观察到代谢降低，但上楼梯任务的代谢降低幅度较小（仅在关节功层面表现出显著降低），可能与上楼梯时力矩需求的特异性有关。
6. **训练数据需求**：前向任务选择减少了标注负担（19 → 7 个任务达到 95% 性能），但仍需要动捕设备和 OpenSim 管线，这限制了该方法在资源受限场景下的推广。

> 【第 6 点对 G-Exo 项目尤其重要——这是我们选择租用高校动捕实验室的主要理论依据。7 个关键任务的采集量远小于 28 个。】

论文核心贡献总结（一页纸）



术语对照表

English	中文	说明
Task-agnostic	任务无关	不依赖任务分类，统一处理所有运动
Biological joint moment	生物关节力矩	人体自身肌肉-骨骼系统产生的净关节力矩
Temporal Convolutional Network (TCN)	时序卷积网络	一种使用膨胀卷积处理序列数据的架构
Quasi-Direct Drive (QDD)	准直驱	低减速比（≤10:1）的执行器，反驱透明度高
Inverse Kinematics (IK)	逆向运动学	从标记点位置反推关节角度
Inverse Dynamics (ID)	逆向动力学	从运动和地面反力反推关节力矩
Ground Reaction Force (GRF)	地面反力	地面对足部的反作用力
Center of Pressure (COP)	压力中心	足底压力分布的合力作用点
Metabolic cost	代谢成本	单位时间/距离的能量消耗（W/kg 或 J/m/kg）
Biological joint positive work	生物关节正功	人体肌肉所做的正向机械功
Forward Activity Selection	前向任务选择	贪心迭代选择对泛化改进最大的训练任务
Dilated Convolution	膨胀卷积	卷积核采样点之间有间隔，增大感受野
Z-score normalization	Z-score 标准化	$(x - \mu) / \sigma$，使特征均值为 0、标准差为 1
RMSE	均方根误差	预测值与真实值偏差的标准差
R^2	决定系数	模型解释的方差比例，越接近 1 越好
Leave-one-subject-out	留一被试交叉验证	每次留一个参与者作为测试集
Zero torque	零力矩条件	外骨骼穿戴但不助力（对照条件）
MIT mode	MIT 模式	一种通过 CAN 总线控制电机的力矩/位置/速度协议

全文翻译完成。译者注释以【】标记，旨在帮助非生物力学/机器人学背景的读者理解论文的技术细节和设计动机。